

**UNIVERSIDAD DE EL SALVADOR
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS**



ETAPA II

**PREDICCIÓN DE BROTES DE DENGUE EN EL SALVADOR UTILIZANDO
DATOS CLIMÁTICOS, EPIDEMIOLÓGICOS E HISTÓRICOS DE CASOS
APLICANDO MODELOS DE MACHINE LEARNING.**

PRESENTADO POR:

CASTILLO HERNANDEZ, MONICA GEORGINA

VILLALTA MARTINEZ, MAHALALEEL

PARA OPTAR AL TÍTULO DE:

INGENIERO EN SISTEMAS INFORMÁTICOS

CIUDAD UNIVERSITARIA, SEPTIEMBRE 2026

Contenido

Introducción.....	2
1.1. Antecedentes del proyecto	2
1.2. Objetivos	2
1.3. Alcance de la etapa 2	3
2. Descripción y preparación de los datos.....	3
2.1. Fuentes de información.....	3
2.2. Descripción del conjunto de datos	4
2.3. Preprocesamiento de los datos	4
2.4. Detección y tratamiento de valores atípicos	4
2.5. Transformación de variables.....	4
2.6. Ingeniería de características	5
2.7. División temporal de los datos	5
3. Metodología experimental	5
3.1. Diseño experimental	6
3.2. Línea base	6
3.3. Modelos de Machine Learning evaluados	6
3.4. Métricas de evaluación	7
3.5. Estrategia de validación	8
3.7. Conjunto de prueba final	9
4. Optimización de hiperparámetros	9
4.1. Estrategia de optimización	9
4.2. GridSearchCV.....	9
4.3. Espacio de búsqueda de hiperparámetros	9
4.4. Configuración de la validación cruzada	9
4.5. Mejores hiperparámetros obtenidos.....	10
4.6. Comparación	10
4.7. Análisis de la mejora obtenida.....	10
5. Modelos avanzados y técnicas de Ensemble	11
5.1. Justificación de modelos avanzados	11
5.2. Modelos adicionales evaluados.....	11
5.3. Deep Learning	11
5.4. Técnicas de Ensemble.....	11
5.5. Comparación de modelos	12
5.6. Modelo sin rezagos de casos.....	12
5.6. Selección del modelo final	13

6. Evaluación rigurosa y resultados finales	13
6.1. Resultados de la validación cruzada	13
6.2. Resultados sobre el conjunto de prueba	13
6.3. Comparación de métricas	13
6.4. Análisis de errores	14
6.5. Casos de mayor error de predicción	14
6.6. Predicción de brotes	14
6.7. Análisis temporal de las predicciones	14
6.8. Comparación entre casos observados y predichos	15
7. Interpretabilidad del modelo	15
7.1. Importancia de variables	15
7.2. Interpretación mediante SHAP	15
7.3. Variables con mayor influencia	15
7.4. Influencia de los rezagos temporales	15
7.5. Influencia de variables climáticas	16
7.6. Interpretación de predicciones individuales	16
8. Análisis ético, sesgos y fairness	16
8.1. Consideraciones éticas	16
8.2. Privacidad y protección de datos	17
8.3. Riesgos asociados al uso de Machine Learning en salud	18
8.4. Identificación de posibles fuentes de sesgo	18
8.5. Evaluación de fairness	20
8.6. Métricas de equidad	20
8.7. Resultados del análisis de sesgos	20
8.8. Medidas de mitigación	21
8.9. Limitaciones éticas del modelo	21
9. Prototipo funcional	21
9.1. Objetivo del prototipo	21
9.2. Arquitectura del sistema	21
9.3. Tecnologías utilizadas	21
9.4. Flujo de funcionamiento	22
9.5. Entrada de datos	22
9.6. Procesamiento	22
9.7. Predicción	23
9.8. Visualización de resultados	23
9.9. Sistema de alertas de brote	24

9.10. Interfaz del prototipo.....	25
9.11. Pruebas funcionales	25
9.12. Limitaciones del prototipo.....	26
10. Impacto social y recomendaciones de política pública	26
10.1. Impacto social esperado	26
10.2. Aplicaciones potenciales en vigilancia epidemiológica.....	26
10.3. Utilidad para la toma de decisiones.....	26
10.4. Identificación temprana de brotes	27
10.5. Optimización de recursos sanitarios.....	27
10.6. Recomendaciones de política pública.....	27
10.7. Recomendaciones para implementación institucional	28
10.8. Escalabilidad del modelo	28
11. Discusión.....	28
11.1. Interpretación de los resultados	28
11.2. Comparación con estudios previos.....	29
11.3. Aportes del estudio.....	30
11.4. Fortalezas	30
11.5. Limitaciones	30
11.6. Implicaciones para la vigilancia del dengue en El Salvador	31
12. Conclusiones	31
12.1. Cumplimiento de los objetivos	31
12.2. Principales hallazgos.....	32
12.3. Modelo seleccionado	32
12.4. Aportes del prototipo.....	32
12.5. Aportes para la toma de decisiones	33
13. Recomendaciones	33
13.1. Recomendaciones técnicas	33
13.2. Recomendaciones institucionales.....	33
13.3. Recomendaciones para futuras investigaciones.....	34
Referencias bibliográficas.....	35
Anexos.....	35
Anexo 1. Etapas del proyecto	35
Anexo 2. Proyecto en github.....	35

Introducción

1.1. Antecedentes del proyecto

El dengue constituye uno de los principales problemas de salud pública asociados con las enfermedades transmitidas por vectores. En latinoamérica, el comportamiento epidemiológico lo influyen múltiples factores ambientales, climáticos, sociales, etc. lo que dificulta establecer patrones de transmisión uniformes. La relación con las condiciones ambientales y el dengue han sido ampliamente estudiadas, siendo las de mayor frecuencia la temperatura, humedad, y precipitación, La revisión de estudios de predicción de dengue en latinoamérica realizada por Cabrera et al destaca precisamente la importancia de incorporar factores ambientales y climáticos dentro de los modelos predictivos. [1] lo cual ha motivado el desarrollo de herramientas orientadas a la anticipación de brotes. La predicción temprana puede contribuir a fortalecer la vigilancia epidemiológica, mejorar la planificación de intervenciones y apoyar en la asignación oportuna de recursos sanitarios.

A partir de lo descrito anteriormente, se identifica la necesidad de desarrollar modelos predictivos que integren información epidemiológica, variables climáticas y características temporales para El Salvador.

En la primera etapa del proyecto, se construyó un dataset correspondiente al 2015-2023, integrado por información epidemiológica y variables climáticas para los 14 departamentos de El Salvador. El conjunto de datos permitió explorar la relación entre el comportamiento histórico de los casos de dengue y diferentes factores ambientales y temporales.

Los resultados obtenidos en esta primera etapa constituyen el punto de partida. Sin embargo, la obtención de un modelo con un desempeño favorable sobre los datos disponibles no es suficiente para establecer su utilidad como herramienta predictiva. Es necesario evaluar de manera rigurosa la estabilidad del modelo, optimizar sus hiperparámetros, comparar diferentes arquitecturas, analizar posibles diferencias de desempeño entre territorios y determinar su comportamiento sobre un conjunto de pruebas independientes.

Por ello, la segunda etapa amplía el trabajo mediante la aplicación de estrategias de optimización de hiperparámetros, validación cruzada temporal, modelos avanzados, técnicas ensemble, análisis de sesgos y fairness, además del desarrollo de un prototipo funcional orientado a la utilización de las predicciones como apoyo a la vigilancia epidemiológica.

1.2. Objetivos

1.2.1. Objetivo general

Desarrollar un modelo para la identificación oportuna de brotes de Dengue en El Salvador mediante el análisis integrado de variables climáticas y datos históricos, para generar un modelo con un nivel de precisión del 75% o superior.

1.2.2. Objetivos específicos

- Recolectar datos históricos de casos de dengue y variables climáticas (temperatura, precipitación, humedad) en El Salvador correspondientes al período de entrenamiento y evaluación asegurando al menos un 75% de nivel de confianza en comparación con al período de prueba.
- Desarrollar tres modelos de Machine Learning, Regresión, Random Forest y XGBoost evaluando su rendimiento con métricas de precisión, orientados a la predicción de brotes de dengue en El Salvador, utilizando variables climáticas y epidemiológicas durante el periodo de estudio.

- Entrenar tres modelos de Machine Learning Random Forest, Regresión Lineal y XGBoost desarrollados utilizando los datos históricos recolectados con los datos correspondientes al período 2014 al 2024
- Evaluar los modelos de machine learning desarrollados, validando los resultados utilizando los datos históricos publicados oficialmente en el período de prueba y métricas del desempeño.
- Desarrollar un sitio web donde se consulten los resultados del modelo de Machine Learning seleccionado y los datos epidemiológicos utilizados para entrenar el modelo.

1.3. Alcance de la etapa 2

En la segunda etapa del proyecto se dará continuidad al desarrollo del modelo predictivo mediante la optimización de sus hiperparámetros, la evaluación de modelos avanzados y técnicas de ensemble, así como la aplicación de estrategias de validación cruzada rigurosa y evaluación sobre un conjunto de pruebas independientes. Asimismo, se incorporará un análisis de posibles sesgos y aspectos éticos asociados al uso de modelos predictivos en salud, y se desarrollará un prototipo funcional orientado a la visualización y utilización de las predicciones. Finalmente, se analizará el potencial impacto social de la herramienta y se formularán recomendaciones orientadas al fortalecimiento de la vigilancia epidemiológica del dengue en El Salvador.

2. Descripción y preparación de los datos

2.1. Fuentes de información

2.1.1 Datos epidemiológicos

Los datos epidemiológicos utilizados en la presente etapa fueron obtenidos de OpenDengue [2], una base de datos global desarrollada por investigadores de la London School of Hygiene & Tropical Medicine que recopila, estandariza y armoniza datos públicos de dengue provenientes de diversas fuentes, incluyendo reportes de ministerios de salud y organismos regionales de salud como la OPS. A diferencia del conjunto de datos utilizado anteriormente, que presenta información desagregada por departamento y semana epidemiológica a partir de boletines publicados por el Ministerio de Salud, el nuevo conjunto de datos corresponde a una serie temporal de cobertura nacional con resolución semanal.

La serie utilizada comprende el periodo 2014–2024, permitiendo incorporar diferentes comportamientos epidemiológicos y varios años con incrementos importantes en la incidencia de dengue. La variable objetivo corresponde al número de casos sospechosos de dengue registrados a nivel nacional. Esta característica representa una diferencia metodológica importante respecto al dataset anterior, en el cual se trabajaba con casos reportados a nivel departamental.

2.1.2 Datos climáticos

Los datos climáticos utilizados en el estudio fueron obtenidos mediante la plataforma NASA POWER, desarrollada por la NASA. Esta plataforma proporciona datos meteorológicos y climatológicos derivados de observaciones satelitales y modelos de asimilación, permitiendo obtener información ambiental para diferentes ubicaciones geográficas y períodos de tiempo. Para este estudio se seleccionaron variables climáticas consideradas potencialmente relevantes para el comportamiento epidemiológico del dengue, principalmente temperatura, precipitación y humedad relativa. Estas variables fueron recopiladas con una resolución

temporal semanal, de manera que pudieran ser integradas con la serie semanal de casos de dengue proveniente de OpenDengue.

2.2. Descripción del conjunto de datos

El conjunto de datos empleado en esta etapa del estudio fue estructurado a nivel país-semana, con el propósito de representar la evolución temporal de los casos de dengue en El Salvador y su posible relación con las condiciones climáticas. El período de análisis comprende desde el año epidemiológico 2014 hasta 2024, utilizando como unidad de análisis la semana epidemiológica.

El dataset contiene 574 registros y 38 variables. Cada registro representa una semana epidemiológica e incluye información temporal, epidemiológica y climática correspondiente al período analizado. La estructura temporal se encuentra definida mediante las variables `anio_epi` y `semana_epi`, complementadas por las fechas de inicio y finalización de cada semana (`calendar_start_date` y `calendar_end_date`).

2.3. Preprocesamiento de los datos

Se incorporaron a variables derivadas destinadas a representar características ambientales potencialmente relevantes para la dinámica del dengue. Entre ellas se encuentran la amplitud térmica, los grados-día, la identificación de períodos en un rango térmico considerado óptimo, la distancia respecto a dicho rango, así como indicadores relacionados con las semanas y la estación lluviosa.

Asimismo, La incorporación de estas variables permite representar dos dimensiones relevantes para el problema de predicción: por una parte, las **condiciones ambientales presentes y recientes** y, por otra, la **dinámica histórica de los casos de dengue**. Los rezagos climáticos permiten explorar posibles efectos retardados de las condiciones ambientales, mientras que los rezagos epidemiológicos permiten representar la dependencia temporal existente en la serie de casos.

2.4. Detección y tratamiento de valores atípicos

La identificación de valores atípicos se realizó mediante el análisis de la distribución y comportamiento temporal de la variable `casos_dengue`. Se observó una distribución asimétrica, con valores entre 0 y 2,897 casos semanales, una media de aproximadamente 339 casos y una mediana de 150 casos.

Los valores elevados observados durante determinados períodos, particularmente en los años 2014, 2015, 2019 y 2022, no fueron considerados automáticamente como errores. Debido a la naturaleza epidemiológica del estudio, estos incrementos pueden representar períodos reales de alta incidencia y constituyen información relevante para el objetivo predictivo. Por esta razón, no se eliminaron ni sustituyeron los valores extremos de la variable objetivo. Para reducir el efecto de la asimetría durante el entrenamiento, se aplicó una transformación logarítmica $\log(1+x)$ sobre los casos. Las predicciones fueron posteriormente transformadas a la escala original para la evaluación de los modelos.

2.5. Transformación de variables

- La variable objetivo del estudio es **casos_dengue**, que representa el número de casos de dengue registrados durante cada semana. El conjunto de datos permite, por tanto, analizar la evolución semanal de la enfermedad a lo largo de once años epidemiológicos y establecer una correspondencia temporal con las variables ambientales.

- Las variables climáticas fueron incorporadas con una resolución semanal y comprenden diferentes características de las condiciones ambientales. Entre ellas se encuentran la temperatura máxima, temperatura mínima y temperatura promedio, la precipitación total, los días de lluvia, la humedad relativa promedio y la velocidad promedio del viento. Estas variables corresponden a la información climática utilizada para caracterizar las condiciones ambientales nacionales durante cada semana del período de estudio.

La tabla resumen de las principales categorías que conforman el conjunto de datos se puede encontrar en el anexo 1.

2.6. Ingeniería de características

En primer lugar, se incorporaron variables derivadas de las condiciones climáticas, entre ellas la amplitud térmica, los grados-día, la identificación de semanas dentro de un rango de temperatura óptimo y la distancia respecto a dicho rango. También se generaron indicadores relacionados con la temporada lluviosa.

Para representar la naturaleza cíclica del año epidemiológico, la variable **semana_epi** se transformó mediante las funciones seno y coseno (**semana_sin** y **semana_cos**). Esto permite representar la continuidad entre el final y el inicio del ciclo anual.

Asimismo, se incorporaron rezagos de uno a cuatro períodos para variables climáticas y para los casos de dengue. Estas características permiten que los modelos consideren posibles efectos retardados de las condiciones ambientales y la evolución reciente de los casos. Adicionalmente, se calcularon **casos_tendencia** y **casos_promedio_4sem** como medidas resumidas del comportamiento reciente de la incidencia.

2.7. División temporal de los datos

Debido a que el estudio se basa en la predicción de casos de dengue mediante datos organizados cronológicamente, se realizó una división temporal del conjunto de datos en tres subconjuntos: **entrenamiento**, **validación** y **prueba final**. Esta estrategia permite respetar el orden temporal de los acontecimientos y simular de manera más adecuada las condiciones en las que el modelo sería utilizado para realizar predicciones sobre períodos futuros.

- El conjunto de **entrenamiento** estuvo conformado por los datos correspondientes al período 2014–2019, los cuales fueron utilizados para entrenar los modelos de Machine Learning y permitir que estos aprendieran las relaciones existentes entre las variables climáticas, epidemiológicas e históricas y la ocurrencia de casos de dengue.
- Posteriormente, se utilizaron los años 2020 y 2021 como conjunto de **validación**, con el propósito de evaluar el comportamiento de los modelos sobre datos correspondientes a un período posterior al utilizado durante el entrenamiento. Este conjunto permitió realizar la comparación de los diferentes modelos y efectuar la selección y ajuste de sus hiperparámetros sin utilizar los datos destinados a la evaluación final.
- Finalmente, los datos correspondientes los años 2022 al 2024 se reservaron como conjunto de **prueba final**. Estos datos no fueron utilizados durante el entrenamiento ni durante el proceso de selección del modelo, por lo que permitieron realizar una evaluación independiente del desempeño del modelo seleccionado sobre un período temporal no observado durante su desarrollo.

Esta metodología evita realizar una división aleatoria de los registros, lo cual podría introducir data leakage, debido a que observaciones correspondientes a períodos futuros podrían ser utilizadas indirectamente durante el entrenamiento del modelo.

3. Metodología experimental

3.1. Diseño experimental

El diseño experimental de la investigación se estableció con el propósito de evaluar la capacidad de diferentes modelos de Machine Learning para predecir la ocurrencia y comportamiento de los casos de dengue en El Salvador, utilizando información climática, epidemiológica e histórica de casos.

El experimento se desarrolló bajo un enfoque cuantitativo y retrospectivo, utilizando registros históricos correspondientes al período de estudio. Debido a la naturaleza temporal de los datos, se mantuvo el orden cronológico de las observaciones durante las diferentes etapas del experimento, evitando una partición aleatoria de los registros.

Como variables de entrada se consideraron las variables climáticas, epidemiológicas e históricas disponibles en el conjunto de datos. Estas variables fueron utilizadas para identificar patrones y relaciones que pudieran contribuir a la predicción de los casos de dengue. La variable objetivo correspondió al número de casos de dengue registrado para el período de predicción, por lo cual, el objetivo principal del modelo es predecir la cantidad de casos de dengue y, mediante un criterio epidemiológico establecido, estas predicciones son utilizadas para identificar anticipadamente períodos con comportamiento epidémico.

En el anexo 2 se puede observar la estructura del proyecto en las diversas etapas.

3.2. Línea base

Con el propósito de establecer un punto de referencia para la evaluación de los modelos de Machine Learning, se definió una línea base, basada en la persistencia temporal de los casos de dengue. Esta estrategia considera que el comportamiento observado en una semana puede utilizarse como referencia para estimar el comportamiento de la semana siguiente, basada en el modelo Naïve Forecast $Y_t = Y_{t-1}$, donde Y_t representa la cantidad de casos de dengue estimada para la semana (t), mientras que Y_{t-1} corresponde a los casos observados durante la semana epidemiológica anterior.

La línea base constituye una estrategia de referencia sencilla, debido a que no requiere el entrenamiento de un modelo de aprendizaje automático ni la incorporación de variables climáticas. Su finalidad es establecer el nivel de desempeño que puede obtenerse utilizando únicamente la información temporal más reciente.

3.3. Modelos de Machine Learning evaluados

Para la predicción de los casos semanales de dengue se evaluaron diferentes modelos de aprendizaje supervisado orientados a problemas de regresión. La selección de los modelos se realizó considerando la naturaleza numérica de la variable objetivo, así como la necesidad de comparar enfoques con diferentes capacidades para representar las relaciones existentes entre los casos históricos y las variables climáticas y epidemiológicas.

Los modelos evaluados permitieron establecer una comparación entre un modelo estadístico de relación lineal y dos métodos basados en árboles de decisión capaces de representar relaciones no lineales y posibles interacciones entre las variables predictoras.

1. **Regresión lineal:** Este modelo se utilizó como uno de los modelos de referencia para estimar la cantidad de casos de dengue a partir de las variables predictoras disponibles. Este modelo supone que existe una relación lineal entre las variables independientes y la variable objetivo, estimando los coeficientes que permiten minimizar el error entre los valores observados y los valores predichos.

Su incorporación permitió evaluar el comportamiento de un modelo relativamente sencillo y establecer una referencia frente a modelos con mayor capacidad para representar

relaciones complejas. Además, facilita la interpretación de la contribución de las variables predictoras dentro de una estructura de relación lineal.

2. **Random Forest:** Este modelo fue incorporado debido a su capacidad para representar relaciones no lineales entre las variables predictoras y la cantidad de casos de dengue. Este algoritmo pertenece a los métodos de aprendizaje conjunto y construye múltiples árboles de decisión, combinando sus predicciones para obtener una estimación final, la utilización de múltiples árboles permite capturar diferentes patrones presentes en los datos y reducir la dependencia de un único árbol de decisión. En el contexto del estudio, este modelo permite analizar de manera conjunta variables relacionadas con el comportamiento histórico de los casos y las condiciones climáticas, sin requerir que la relación entre estas variables y los casos de dengue sea estrictamente lineal.
3. **XGBoost Regressor:** Este modelo fue seleccionado como un segundo modelo basado en árboles de decisión, utilizando el enfoque de gradient boosting. A diferencia de Random Forest, donde los árboles se construyen de manera independiente, XGBoost genera los árboles de forma secuencial, procurando que cada nuevo árbol contribuya a corregir los errores producidos por los árboles anteriores. Este enfoque permite modelar relaciones no lineales y complejas entre las variables predictoras y la variable objetivo. Su incorporación permitió comparar el desempeño de un método de boosting con el de un modelo de ensamble basado en árboles independientes y con el modelo de Regresión Lineal.

Los tres modelos fueron evaluados bajo las mismas condiciones experimentales, utilizando el mismo conjunto de variables predictoras y respetando la división cronológica establecida entre los conjuntos de entrenamiento, validación y prueba. Esto permitió realizar una comparación homogénea del desempeño de cada algoritmo. La comparación se orientó a determinar cuál de los modelos presenta un menor error en la predicción de los casos semanales de dengue y, posteriormente, seleccionar el modelo con mejor comportamiento para la evaluación final sobre el período de prueba.

De esta manera, la evaluación no se limita a determinar qué algoritmo obtiene el menor error, sino que permite analizar si los modelos con mayor capacidad para representar relaciones no lineales proporcionan una mejora respecto a un modelo lineal de referencia.

3.4. Métricas de evaluación

Para la evaluación del desempeño de los modelos, se utilizaron métricas de evaluación correspondientes a problemas de regresión, debido a que la variable del estudio corresponde a la cantidad semanal de casos de dengue. La utilización de las métricas seleccionadas, permitió realizar el análisis de desempeño de los modelos desde diferentes perspectivas, considerando tamaños promedios de los errores, presencia de los errores y la capacidad de cada modelo para explicar la variabilidad observada en los casos de dengue.

1. **Error Absoluto Medio (MAE):** Esta métrica permite interpretar de manera directa cuánto se desvía, en promedio, la predicción respecto al número real de casos. Un valor menor de MAE representa un menor error promedio y, por tanto, un mejor desempeño predictivo.
2. **Raíz del error cuadrático medio (RMSE):** Al elevar los errores al cuadrado, esta métrica asigna un mayor peso a las predicciones que presentan errores de gran magnitud. Esto resulta particularmente relevante para el estudio, debido a que el comportamiento de los casos de dengue puede presentar incrementos importantes durante determinadas semanas epidemiológicas. Al igual que el MAE, un menor valor de RMSE indica un mejor desempeño del modelo.

3. **Coefficiente de determinación (R^2):** Un valor de R^2 más cercano a 1 indica una mayor capacidad del modelo para explicar la variabilidad de la variable objetivo. Por el contrario, valores bajos indican una menor capacidad explicativa. Esta métrica se utilizará como medida complementaria a MAE y RMSE, ya que un modelo puede presentar errores relativamente bajos sin necesariamente explicar una proporción elevada de la variabilidad de los casos.

Las métricas se calcularon para los modelos evaluados bajo las mismas condiciones experimentales, permitiendo realizar una comparación homogénea de su desempeño. Para MAE y RMSE, se consideró como favorable un menor valor, mientras que para R^2 se consideró favorable un mayor valor. La selección del modelo con mejor desempeño se realizará considerando conjuntamente estas métricas y el comportamiento observado durante las etapas de validación y prueba. De esta forma, la evaluación no dependerá de una única medida de desempeño, sino de un análisis integral de la capacidad predictiva de los modelos. Los resultados numéricos obtenidos para cada métrica se presentarán posteriormente en el capítulo correspondiente a los resultados del estudio.

3.5. Estrategia de validación

La estrategia de validación se diseñó respetando el orden cronológico, esta consideración es fundamental para evitar que información correspondiente a futuros períodos sea utilizada durante el entrenamiento de los modelos, lo que podría generar una estimación optimista de la capacidad predictiva. A diferencia de una división aleatoria de los datos, en la cual las observaciones de diferentes períodos podrían mezclarse entre los conjuntos de entrenamiento y evaluación, en este estudio se estableció una división temporal que simula las condiciones en las que el modelo sería utilizado en un escenario real: utilizar información histórica para realizar predicciones sobre períodos posteriores.

1. **División temporal de los datos:** El conjunto de datos fué dividido cronológicamente en tres grupos, los cuales podemos observarlos en el apartado **División temporal de datos**.
2. **Prevención de fuga de la información temporal:** De igual forma, se evitó realizar una división aleatoria de las observaciones. y las variables predictoras fueron construidas considerando únicamente información disponible hasta el período que se pretende predecir. En particular, las variables de rezago utilizadas en el estudio representan información correspondiente a semanas anteriores, permitiendo que el modelo utilice el comportamiento histórico de los casos y de las variables climáticas sin incorporar información posterior a la semana objetivo.

Esta estrategia permite mantener una relación temporal coherente entre las variables utilizadas como entrada y la variable objetivo, reduciendo el riesgo de fuga de información, haciendo que la evaluación represente de mejor manera un escenario de predicción temporal.

3. **Selección del modelo:** Mediante los modelos descritos en el apartado **Modelos de Machine Learning evaluados** junto con los criterios de evaluación y las métricas definidas en el apartado **Métricas de evaluación**, se seleccionó el modelo que representó el comportamiento más favorable. Una vez seleccionado, se evaluó su desempeño sobre el conjunto de datos correspondiente, lo que permitió determinar la capacidad predictiva sobre los datos correspondientes a períodos que no fueron utilizados durante los procesos anteriores,

De esta manera, la estrategia de validación permite diferenciar entre el proceso de aprendizaje, la selección del modelo y la evaluación final, manteniendo en todo momento el orden temporal de la serie de casos de dengue.

3.7. Conjunto de prueba final

Durante el proceso de desarrollo, los modelos fueron entrenados, comparados con su desempeño y probados con los años correspondientes anteriormente detallados, los cuales ayudaron en la selección del modelo. El conjunto de prueba no fue utilizado para ajustar los modelos ni para tomar decisiones relacionadas con su selección, de esta manera, la evaluación final busca aproximarse a las condiciones de un escenario real, en el cual el modelo utiliza información histórica para generar predicciones sobre períodos futuros.

Una vez seleccionado el modelo con base en el desempeño observado durante la etapa de validación, este fue evaluado sobre el conjunto de prueba final mediante las métricas definidas en la sección **Métricas de evaluación**. Los resultados obtenidos en este conjunto representan el desempeño final del modelo y se presentan en el capítulo correspondiente a los resultados, y el mantenimiento del conjunto de prueba completamente separado hasta la etapa final constituye una medida para reducir el riesgo de sobreajuste al proceso de selección y proporciona una evaluación independiente de la capacidad predictiva del modelo.

4. Optimización de hiperparámetros

4.1. Estrategia de optimización

La optimización de hiperparámetros tuvo como propósito mejorar el desempeño de los modelos basados en árboles de decisión, identificando la combinación de parámetros que minimiza el error de predicción sin comprometer la capacidad de generalización. Dado el carácter temporal de los datos, la estrategia de optimización se diseñó respetando el orden cronológico de las observaciones, evitando que información de períodos futuros influyera en la selección de los parámetros. Se optimizaron los dos modelos basados en árboles, Random Forest y XGBoost, por ser los que presentaron mayor capacidad para representar relaciones no lineales durante la etapa anterior.

4.2. GridSearchCV

Para la búsqueda de los hiperparámetros óptimos se utilizó GridSearchCV, un método de búsqueda exhaustiva que evalúa todas las combinaciones posibles dentro de un espacio de parámetros definido. Se seleccionó este método sobre alternativas como RandomizedSearchCV debido a que el espacio de búsqueda considerado era acotado, lo que permitía explorar todas las combinaciones de manera completa en un tiempo razonable. Adicionalmente, GridSearchCV ofrece la ventaja de una interpretación clara y reproducible del proceso de selección, ya que evalúa de manera sistemática cada combinación de parámetros bajo las mismas condiciones.

4.3. Espacio de búsqueda de hiperparámetros

Para Random Forest se exploraron los siguientes parámetros: número de árboles (200, 300 y 500), profundidad máxima (8, 12, 16 y sin límite), número mínimo de muestras por hoja (1, 3 y 5) y número de características consideradas en cada división (raíz cuadrada del total y la totalidad de las características). Para XGBoost se exploraron el número de árboles (200, 400 y 600), la profundidad máxima (3, 5 y 7), la tasa de aprendizaje (0.03, 0.05 y 0.1) y la fracción de submuestreo (0.8 y 1.0). Estos rangos se establecieron considerando valores comúnmente recomendados para cada algoritmo y las características del conjunto de datos.

4.4. Configuración de la validación cruzada

La validación cruzada empleada durante la optimización correspondió a la validación cruzada para series temporales (TimeSeriesSplit), configurada con cinco divisiones. A diferencia de la validación cruzada tradicional, que asigna las observaciones de manera aleatoria a los distintos pliegues, esta técnica respeta el orden temporal de los datos: cada pliegue entrena con un bloque de observaciones y valida con el bloque inmediatamente posterior en el tiempo. De esta manera, el proceso de optimización simula las condiciones reales de uso del modelo, en las que se dispone de información histórica para predecir períodos futuros, y se evita la fuga de información temporal que introduciría una estimación optimista del desempeño.

4.5. Mejores hiperparámetros obtenidos

Los hiperparámetros que produjeron el mejor desempeño durante la validación cruzada temporal se presentan a continuación:

Modelo	Hiperparametros óptimos
Random Forest	max_depth=12, max_features=1.0, min_samples_leaf=5, n_estimators=500
XGBoost	learning_rate=0.03, max_depth=3, n_estimators=200, subsample=0.8

Resulta relevante que XGBoost seleccionó árboles de poca profundidad (max_depth=3) y una tasa de aprendizaje baja (0.03). Esta configuración corresponde a un modelo más conservador, lo que sugiere que un aprendizaje gradual y con menor complejidad por árbol favorece la generalización en este conjunto de datos, reduciendo el sobreajuste observado en la configuración inicial.

4.6. Comparación

Baseline vs. modelo optimizado

La siguiente tabla presenta el desempeño de los modelos antes y después de la optimización, evaluados sobre el conjunto de prueba (2022-2024), junto con la línea base de referencia:

Modelo	MAE	RMSE	R ²
Baseline (persistencia)	29.82	50.86	0.875
Random Forest original	43.46	59.90	0.826
Random Forest optimizado	37.55	—	0.858
XGBoost original	45.83	61.81	0.815
XGBoost optimizado	34.07	50.82	0.875

4.7. Análisis de la mejora obtenida

La optimización produjo una mejora en ambos modelos. XGBoost presentó la mejora más notable, con una reducción del error absoluto medio del 26% (de 45.83 a 34.07), mientras que Random Forest redujo su error en un 14% (de 43.46 a 37.55). El modelo XGBoost optimizado alcanzó un coeficiente de determinación de 0.875, igualando el desempeño de la línea base y superándose ligeramente a la raíz del error cuadrático medio.

Un hallazgo relevante de esta etapa es la fuerte competitividad de la línea base. El hecho de que un método tan sencillo como la persistencia temporal alcance un R^2 de 0.875 revela que la transmisión del dengue presenta una inercia semanal considerable, en la que el número de casos evoluciona de manera gradual sin variaciones bruscas entre semanas consecutivas. Esta característica hace que la línea base sea difícil de superar en el horizonte de una semana. Sin embargo, esta ventaja de la línea base se limita a la predicción a corto plazo, ya que requiere conocer los casos de la semana inmediatamente anterior. Los modelos optimizados, al incorporar variables climáticas y estacionales, conservan capacidad predictiva en horizontes más amplios, escenario de mayor utilidad para la planificación sanitaria.

5. Modelos avanzados y técnicas de Ensemble

5.1. Justificación de modelos avanzados

Después de optimizar los modelos individuales, se buscó determinar si era posible mejorar aún más el desempeño combinando varios modelos mediante técnicas de ensemble. Estas técnicas combinan las predicciones de distintos modelos con la idea de que la unión de varios pueda dar mejores resultados que cada uno por separado. También se realizó un experimento adicional orientado a evaluar la capacidad predictiva del modelo cuando no se dispone de información reciente de casos, con el fin de analizar su utilidad para predicciones a mayor plazo.

5.2. Modelos adicionales evaluados

Los modelos base utilizados para los ensembles fueron los mismos que mostraron mejor desempeño en la etapa anterior: Random Forest y XGBoost, ambos con sus hiperparámetros ya optimizados. Sobre estos se construyeron las técnicas de ensemble descritas más adelante.

5.3. Deep Learning

Se evaluó la posibilidad de incorporar un modelo de aprendizaje profundo, específicamente una red neuronal recurrente del tipo LSTM, que suele emplearse para series temporales. Sin embargo, se determinó que este tipo de modelo no era el más adecuado para el conjunto de datos disponible. Las redes neuronales profundas requieren una gran cantidad de datos para entrenarse de forma efectiva, y el conjunto de datos del estudio cuenta con 574 registros semanales, una cantidad reducida para este tipo de arquitectura. Además, los modelos de aprendizaje profundo son más difíciles de interpretar, lo que representa una desventaja en un contexto de salud pública donde es importante entender por qué el modelo genera determinada predicción. Por estas razones, se optó por priorizar los modelos basados en árboles y las técnicas de ensemble, más apropiados para el tamaño y las características de los datos.

5.4. Técnicas de Ensemble

Se implementaron dos técnicas de ensemble sobre los modelos base optimizados:

- **Voting (votación).** Esta técnica combina las predicciones de Random Forest y XGBoost calculando el promedio de ambas. De esta forma, la predicción final considera el aporte de los dos modelos por igual.
- **Stacking (apilamiento).** En esta técnica, las predicciones de Random Forest y XGBoost se utilizan como entrada de un tercer modelo, en este caso una regresión Ridge, que aprende la mejor manera de combinarlas. Se trata de un enfoque más elaborado que el Voting, ya que el modelo final determina cómo ponderar cada predicción en lugar de simplemente promediarlas.

5.5. Comparación de modelos

Los resultados de las técnicas de ensemble, evaluados sobre el conjunto de prueba (2022-2024), se comparan con los modelos individuales optimizados en la siguiente tabla:

Modelo	MAE	R ²
Random Forest optimizado	37.55	0.858
XGBoost optimizado	34.07	0.875
Ensemble Voting	34.76	0.874
Ensemble Stacking	37.86	0.851

Los resultados muestran que las técnicas de ensemble no lograron superar al mejor modelo individual. El ensemble Voting alcanzó un desempeño muy similar al de XGBoost optimizado, mientras que el Stacking obtuvo un resultado inferior. Este comportamiento se explica porque Random Forest y XGBoost son ambos modelos basados en árboles y tienden a cometer errores parecidos, por lo que combinarlos no aporta la diversidad necesaria para mejorar el resultado. Se concluye que, para este problema, el modelo XGBoost optimizado de manera individual constituye la opción más eficiente.

5.6. Modelo sin rezagos de casos.

Como experimento complementario, se entrenaron los modelos excluyendo las variables de rezago de casos (es decir, la información de casos de semanas anteriores), manteniendo únicamente las variables climáticas, estacionales y las derivadas del clima. El propósito de este experimento fue evaluar cuánto del desempeño del modelo depende de la información reciente de casos y determinar si es posible predecir el dengue basándose principalmente en el clima, escenario que sería necesario para predicciones a mayor plazo.

Escenario	MAE	R ²
Con rezagos de casos (Stacking)	37.86	0.851
Sin rezagos de casos (Stacking)	109.50	-0.099

Los resultados muestran una caída drástica en el desempeño al eliminar los rezagos de casos: el coeficiente de determinación pasó de 0.851 a un valor negativo, lo que indica que el modelo sin esa información predice peor que simplemente utilizar el promedio de casos. Los modelos basados únicamente en variables climáticas no lograron identificar los años epidémicos.

Este hallazgo tiene una implicación importante: el dengue en El Salvador no es predecible únicamente a partir del clima. Las variables climáticas crean las condiciones para la proliferación del mosquito, pero no determinan por sí solas cuándo ocurre un brote, el cual depende de factores no capturados por el clima, como la inmunidad de la población, los serotipos del virus en circulación y la densidad del vector. La información reciente de casos captura de manera indirecta estos factores. En consecuencia, la vigilancia epidemiológica continua resulta indispensable y no puede sustituirse por un modelo basado exclusivamente en variables climáticas.

5.6. Selección del modelo final

Con base en los resultados obtenidos, se seleccionó el modelo XGBoost optimizado como modelo final del estudio. Este modelo presentó el mejor desempeño en términos de error absoluto medio (34.07) y coeficiente de determinación (0.875), igualando a la línea base y superando a las técnicas de ensemble. Adicionalmente, ofrece la ventaja de ser interpretable mediante técnicas como SHAP, lo que resulta valioso para comprender los factores que influyen en sus predicciones.

6. Evaluación rigurosa y resultados finales

6.1. Resultados de la validación cruzada

La validación cruzada temporal, aplicada durante la optimización de hiperparámetros, permitió evaluar la estabilidad de los modelos a lo largo de distintos períodos. Al utilizar cinco divisiones que respetan el orden cronológico, se confirmó que los hiperparámetros seleccionados mantienen un comportamiento consistente cuando se aplican a diferentes bloques temporales, y no se ajustan únicamente a una partición específica de los datos. Esto proporciona mayor confianza en que el desempeño observado no es producto del azar en una división particular.

6.2. Resultados sobre el conjunto de prueba

El modelo final (XGBoost optimizado) fue evaluado sobre el conjunto de prueba correspondiente a los años 2022 a 2024, que no fue utilizado en ninguna etapa previa del desarrollo. Los resultados obtenidos fueron un error absoluto medio (MAE) de 34.07 casos, una raíz del error cuadrático medio (RMSE) de 50.82 casos y un coeficiente de determinación (R^2) de 0.875. Estos valores indican que el modelo explica aproximadamente el 87% de la variabilidad de los casos de dengue en el período de prueba.

6.3. Comparación de métricas

Modelo	MAE	RMSE	R^2
Baseline (persistencia)	29.82	50.86	0.875
Random Forest optimizado	37.55	—	0.858

Modelo	MAE	RMSE	R ²
XGBoost optimizado (final)	34.07	50.82	0.875
Ensemble Voting	34.76	—	0.874

El modelo final iguala el desempeño de la línea base en cuanto a coeficiente de determinación y la supera ligeramente en la raíz del error cuadrático medio. Como se explicó anteriormente, la fuerte competitividad de la línea base se debe a la inercia semanal característica del dengue.

6.4. Análisis de errores

Para comprender mejor el comportamiento del modelo, se analizó la distribución de los errores de predicción a lo largo del período de prueba. Se observó que el modelo mantiene un balance entre subestimaciones y sobreestimaciones, con aproximadamente el 51% de las semanas subestimadas y el 49% sobreestimadas, lo que indica la ausencia de un sesgo sistemático generalizado. El análisis por temporada reveló que las sobreestimaciones tienden a concentrarse en la temporada de alta transmisión, mientras que las subestimaciones se presentan mayormente en la temporada baja.

6.5. Casos de mayor error de predicción

Los errores de mayor magnitud se presentaron durante las semanas de transición hacia los períodos de mayor transmisión y en las semanas cercanas a los picos epidémicos. Esto es esperable, ya que son los momentos en que los casos cambian con mayor rapidez y resultan más difíciles de predecir. En términos absolutos, el error fue mayor en el año epidémico 2022, aunque proporcionalmente el modelo mantuvo un buen desempeño en ese año.

6.6. Predicción de brotes

Uno de los resultados más relevantes del estudio es la capacidad del modelo para dimensionar los brotes. En el año epidémico 2022, el modelo estimó un total anual de aproximadamente 17,200 casos frente a los 16,542 casos reales, lo que representa un error cercano al 4%. Esta capacidad para aproximar la magnitud de un período epidémico resulta valiosa para la planificación de la respuesta sanitaria.

6.7. Análisis temporal de las predicciones

El desempeño del modelo evaluado por año se presenta a continuación:

Año	MAE	Casos reales	Casos predichos	Tipo de año
2022	58.30	16,542	17,200	Epidémico
2023	35.46	5,788	5,432	Baja transmisión
2024	18.90	8,552	8,084	Baja transmisión

El análisis muestra que el modelo mantiene un desempeño adecuado tanto en años epidémicos como en años de baja transmisión, con estimaciones anuales cercanas a los valores reales en todos los casos.

6.8. Comparación entre casos observados y predichos

La comparación gráfica entre los casos observados y los predichos a lo largo del período de prueba muestra que el modelo sigue de manera adecuada la forma general de la curva de casos, capturando tanto los períodos de aumento como los de descenso. El modelo reproduce correctamente el patrón estacional y logra aproximar los momentos de mayor transmisión, aunque con cierta dificultad para predecir con exactitud los valores máximos en las semanas pico, como es común en este tipo de modelos.

7. Interpretabilidad del modelo

7.1. Importancia de variables

Para comprender el funcionamiento del modelo seleccionado, se analizó la importancia de las variables que utiliza para generar sus predicciones. Este análisis permite identificar qué factores tienen mayor influencia sobre la estimación de casos de dengue y verificar si el comportamiento del modelo es coherente con el conocimiento epidemiológico de la enfermedad. La importancia de las variables se evaluó mediante dos enfoques: la importancia interna que proporciona el modelo XGBoost y el análisis mediante valores SHAP.

7.2. Interpretación mediante SHAP

SHAP (SHapley Additive exPlanations) es una técnica basada en la teoría de juegos que asigna a cada variable una contribución específica en cada predicción. A diferencia de la importancia interna del modelo, que solo indica qué variables son importantes, SHAP permite conocer cómo influye cada variable en las predicciones, es decir, si empuja la estimación hacia valores más altos o más bajos y con qué magnitud. Se aplicó SHAP sobre el modelo final para obtener una interpretación detallada de su comportamiento.

7.3. Variables con mayor influencia

El análisis mediante SHAP identificó que las variables de mayor influencia sobre las predicciones del modelo son los rezagos de casos, es decir, la información de casos de las semanas anteriores. La variable más influyente resultó ser el promedio de casos de las últimas cuatro semanas (`casos_promedio_4sem`), con un valor SHAP medio de 0.284, seguida por el número de casos de la semana anterior (`casos_dengue_lag1`) y por otros rezagos de casos. En conjunto, las variables relacionadas con el historial reciente de casos concentran la mayor parte de la capacidad predictiva del modelo. Este resultado coincide con el obtenido mediante la importancia interna del modelo, lo que otorga mayor solidez al hallazgo.

7.4. Influencia de los rezagos temporales

La fuerte influencia de los rezagos de casos confirma la naturaleza autocorrelacionada del dengue, es decir, la fuerte dependencia entre el número de casos de una semana y los de las semanas anteriores. Este comportamiento es coherente con la dinámica de transmisión de la enfermedad: cuando existe un número elevado de casos en las semanas recientes, hay más personas infectadas capaces de transmitir el virus a través del mosquito, lo que tiende a generar más casos en las semanas siguientes. El modelo captura correctamente este comportamiento, otorgando un peso importante a la evolución reciente de los casos. El hecho de que el promedio de las últimas cuatro semanas sea la variable más influyente sugiere que

el modelo se apoya en la tendencia sostenida de los casos más que en el valor puntual de una sola semana, lo que representa una medida más estable del comportamiento de la enfermedad.

7.5. Influencia de variables climáticas

Entre las variables climáticas, la de mayor influencia según el análisis SHAP fue la precipitación de dos semanas atrás (**precip_total_lag2**). Esto es coherente con el ciclo biológico del mosquito, ya que la lluvia genera criaderos cuyo efecto sobre la población del vector y sobre la transmisión se manifiesta algunas semanas después. Aunque las variables climáticas tienen una influencia menor que los rezagos de casos, su aporte es coherente con el conocimiento epidemiológico. También se observó que la variable correspondiente al identificador del comportamiento estacional contribuye a las predicciones, lo que refleja la marcada estacionalidad del dengue.

7.6. Interpretación de predicciones individuales

Además del análisis global, SHAP permite explicar predicciones individuales, mostrando cómo cada variable contribuye a la estimación de una semana específica. Esta capacidad resulta valiosa en el contexto de la salud pública, ya que permite explicar a las autoridades sanitarias por qué el modelo estima un aumento o disminución de casos en una semana determinada. Por ejemplo, el modelo puede indicar que prevé un incremento debido a que los casos vienen elevados en las últimas semanas y a que se registraron precipitaciones significativas semanas atrás. Esta transparencia facilita la interpretación de los resultados y aumenta la confianza en la herramienta.

8. Análisis ético, sesgos y fairness

8.1. Consideraciones éticas

El desarrollo de un modelo de Machine Learning para la predicción de brotes de dengue implica considerar aspectos éticos relacionados con el uso de los datos, la interpretación de los resultados y el posible impacto de las predicciones en la toma de decisiones. En este proyecto, las consideraciones éticas se orientan principalmente hacia el uso responsable de la información epidemiológica y climática, la protección de la privacidad y la transparencia en el funcionamiento del modelo.

En primer lugar, se debe garantizar que la información utilizada para el desarrollo del modelo sea empleada exclusivamente con fines de investigación y análisis epidemiológico. Debido a que los datos relacionados con enfermedades pueden contener información potencialmente sensible, es importante evitar la utilización o exposición de datos que permitan identificar directamente a personas. En este sentido, el modelo desarrollado se orienta al análisis agregado de casos y variables ambientales, por lo que los resultados no buscan identificar individuos, sino reconocer patrones epidemiológicos y generar estimaciones a nivel temporal y territorial.

Asimismo, se debe considerar que las predicciones generadas por el modelo constituyen una herramienta de apoyo y no sustituyen el criterio de los profesionales responsables de la vigilancia epidemiológica. Una predicción elevada de casos no implica necesariamente que se produzca un brote, de la misma manera que una predicción baja no garantiza la ausencia de transmisión. Por ello, los resultados deben interpretarse conjuntamente con la información epidemiológica disponible y con el conocimiento de los responsables de la toma de decisiones.

Otro aspecto relevante corresponde a la calidad y representatividad de los datos utilizados, es que los modelos de Machine Learning pueden producir errores, inconsistencias o limitaciones presentes en los datos históricos con los que fueron entrenados, por esta razón, las predicciones deben interpretarse considerando las características del conjunto de datos, el período analizado, la disponibilidad de información y las variables incorporadas al modelo. También es importante mantener transparencia respecto al funcionamiento y las limitaciones del modelo, en el presente proyecto se documentan las variables utilizadas, el proceso de preparación de los datos, la estrategia de división temporal, los métodos de evaluación y el desempeño obtenido. Esto permite que los resultados puedan ser analizados y reproducidos, evitando presentar las predicciones como resultados absolutos o infalibles.

Finalmente, el uso ético del modelo requiere que sus resultados sean empleados para apoyar acciones orientadas a la prevención y vigilancia de la enfermedad, evitando generar interpretaciones que puedan producir estigmatización de determinadas poblaciones o territorios. Las predicciones deben entenderse como información de apoyo para identificar posibles períodos o zonas de mayor riesgo y contribuir a una mejor planificación de las acciones de vigilancia y respuesta sanitaria.

8.2. Privacidad y protección de datos

La privacidad y protección de los datos constituye un aspecto fundamental en el desarrollo de modelos de Machine Learning aplicados al ámbito de la salud. En el presente proyecto, los datos empleados para el desarrollo del modelo corresponden a información epidemiológica histórica agregada y variables climáticas. El análisis se realiza sobre cantidades de casos de dengue asociadas a períodos temporales y ubicaciones geográficas, sin que el modelo requiera información directamente identificable de los pacientes, como nombres, números de expediente, direcciones particulares u otros identificadores personales, esta característica permite reducir el riesgo de exposición de información personal, debido a que el objetivo del modelo es identificar patrones y realizar predicciones a nivel epidemiológico y territorial, y no analizar o identificar individuos. Por tanto, los resultados generados por el sistema deben mantenerse igualmente en un nivel agregado, evitando incorporar información personal innecesaria en la aplicación o en las visualizaciones.

Asimismo, durante las etapas de preparación, entrenamiento y evaluación del modelo, se debe evitar la incorporación de variables que permitan identificar directa o indirectamente a una persona cuando estas no sean necesarias para el objetivo de la investigación. De igual manera, cualquier información utilizada durante el proceso debe manejarse únicamente para los fines establecidos en el proyecto y mantenerse bajo las medidas de seguridad correspondientes.

La aplicación desarrollada para la predicción de dengue debe seguir el mismo principio de anonimización de datos. Las variables solicitadas al usuario deben limitarse a aquellas necesarias para generar la predicción, evitando recopilar información personal que no aporte al funcionamiento del modelo. Además, los resultados mostrados deben corresponder a estimaciones epidemiológicas y no contener datos individuales de pacientes, finalmente, la protección de los datos no debe limitarse únicamente a la información utilizada para entrenar el modelo, sino que debe contemplar todo el ciclo de vida de los datos: recopilación, almacenamiento, procesamiento, utilización y presentación de resultados. De esta manera, se busca garantizar que el desarrollo de la herramienta mantenga un equilibrio entre la utilidad de la información epidemiológica para la vigilancia del dengue y la protección de la privacidad de las personas.

8.3. Riesgos asociados al uso de Machine Learning en salud

El uso de técnicas de Machine Learning en el ámbito de la salud permite analizar grandes cantidades de información y generar estimaciones que pueden contribuir a la vigilancia epidemiológica. Sin embargo, su aplicación también implica riesgos relacionados con la calidad de los datos, el comportamiento de la enfermedad y las características propias del modelo desarrollado. En el presente proyecto se identificaron los siguientes riesgos específicos.

- **Desbalance en la distribución de los casos de dengue.** La cantidad de casos no se distribuye de manera uniforme entre los diferentes períodos y territorios analizados. La presencia de años con un comportamiento epidemiológico considerablemente diferente puede influir en el aprendizaje del modelo y provocar que este otorgue mayor importancia a determinados patrones históricos. Esto puede afectar su capacidad para representar adecuadamente períodos con niveles de transmisión diferentes.
- **Cambios en el comportamiento epidemiológico a través del tiempo:** El dengue presenta variaciones temporales y estacionales, por lo que las relaciones identificadas a partir de datos históricos no necesariamente permanecen constantes. Los patrones observados durante los años utilizados para el entrenamiento pueden modificarse en períodos posteriores debido a cambios ambientales, epidemiológicos o sociales. Por esta razón, el desempeño del modelo puede disminuir cuando se presentan condiciones diferentes a las observadas durante su entrenamiento.
- **Limitaciones en la disponibilidad y calidad de los datos históricos:** El modelo depende de la información epidemiológica y climática utilizada para su entrenamiento. La existencia de valores faltantes, registros inconsistentes, variaciones en los sistemas de vigilancia o diferencias en la disponibilidad de información puede introducir incertidumbre en las predicciones. Estas limitaciones pueden afectar tanto el aprendizaje del modelo como la evaluación de su desempeño.
- **Limitaciones en la generalización territorial:** Los patrones de transmisión del dengue pueden presentar diferencias entre departamentos de El Salvador debido a características climáticas, ambientales y epidemiológicas particulares. En consecuencia, un modelo con un desempeño adecuado a nivel general puede presentar un comportamiento diferente en determinados territorios. Las predicciones deben interpretarse considerando estas posibles diferencias y evitando asumir que el comportamiento del modelo es idéntico para todas las regiones.
- **Riesgo de sobreajuste a patrones históricos:** Debido a que el modelo aprende a partir de observaciones correspondientes a períodos anteriores, existe el riesgo de que aprenda relaciones demasiado específicas del conjunto de entrenamiento y que estas no se mantengan al enfrentarse a nuevos períodos. Para reducir este riesgo, en el proyecto se realizó una separación temporal de los datos para evaluar el comportamiento del modelo sobre períodos posteriores a los utilizados durante el entrenamiento.

Finalmente, estos riesgos evidencian que el desempeño de un modelo de Machine Learning no depende únicamente del algoritmo seleccionado, sino también de la calidad, representatividad y temporalidad de los datos utilizados. Por ello, cualquier implementación futura del sistema deberá contemplar la actualización periódica de los datos, el monitoreo del desempeño del modelo y la revisión de sus resultados antes de utilizar las predicciones como apoyo para la toma de decisiones en salud pública.

8.4. Identificación de posibles fuentes de sesgo

La identificación de posibles fuentes de sesgo es importante para determinar si las predicciones generadas por el modelo pueden verse afectadas de manera sistemática por las características de los datos utilizados durante su desarrollo. En este proyecto, los posibles sesgos se analizaron considerando principalmente las dimensiones temporal, territorial y relacionada con la disponibilidad y calidad de la información.

- **Sesgo temporal:** El conjunto de datos comprende diferentes años y presenta variaciones importantes en el comportamiento de los casos de dengue. Algunos períodos pueden estar sobrerrepresentados debido a la presencia de temporadas con una mayor cantidad de casos, mientras que otros pueden presentar niveles de transmisión considerablemente menores. Esta distribución puede provocar que el modelo aprenda con mayor intensidad los patrones correspondientes a determinados períodos. La presencia de cambios en la dinámica de la enfermedad también puede afectar la capacidad del modelo para representar adecuadamente períodos futuros.
- **Sesgo territorial:** Los casos de dengue no presentan necesariamente una distribución homogénea entre los departamentos y municipios de El Salvador. Los territorios con una mayor cantidad histórica de casos pueden tener una mayor influencia sobre el aprendizaje del modelo que aquellos con menor cantidad de registros. Como consecuencia, el modelo podría representar mejor los patrones predominantes en determinados departamentos y presentar mayor incertidumbre en aquellos con menor representación.
- **Sesgo asociado a la disponibilidad de información:** Las diferencias en la cantidad o calidad de los registros disponibles para determinados períodos pueden influir en el comportamiento del modelo. Cuando una variable presenta mayor disponibilidad de información en ciertos períodos que en otros, el modelo puede aprender relaciones que reflejen parcialmente la forma en que se registraron los datos y no únicamente el comportamiento real de la enfermedad.
- **Sesgo relacionado con variables climáticas:** Las variables climáticas utilizadas en el proyecto provienen de fuentes de información que representan condiciones ambientales mediante mediciones y estimaciones para determinadas ubicaciones geográficas. Estas variables constituyen una aproximación de las condiciones ambientales de los territorios y no necesariamente reflejan las condiciones específicas de cada comunidad o localidad. Por ello, pueden existir diferencias entre las condiciones climáticas representadas en los datos y las condiciones experimentadas en determinadas zonas.
- **Sesgo por variables no observadas:** El modelo se construye a partir de las variables disponibles en el conjunto de datos. Sin embargo, existen factores que pueden influir en la transmisión del dengue y que no fueron incorporados al análisis, como las acciones de control vectorial, movilidad poblacional, condiciones socioeconómicas, características de las viviendas o cambios en las estrategias de vigilancia. La ausencia de estos factores puede hacer que determinadas relaciones aprendidas por el modelo representen parcialmente otros factores no observados.
- **Sesgo por cambios en la vigilancia epidemiológica.** Las modificaciones en los mecanismos de detección, notificación y vigilancia pueden generar variaciones en la cantidad de casos registrados que no necesariamente corresponden a cambios equivalentes en la transmisión real de la enfermedad. En consecuencia, el modelo podría interpretar cambios en el registro epidemiológico como cambios en el comportamiento del dengue.

Finalmente, estos posibles sesgos no implican necesariamente que el modelo sea inválido, sino que representan factores que deben considerarse al interpretar sus resultados. Su

identificación permite reconocer las condiciones bajo las cuales las predicciones podrían presentar un desempeño desigual y establece la necesidad de evaluar periódicamente el comportamiento del modelo en diferentes periodos y territorios. En el contexto del presente proyecto, la identificación de estas fuentes de sesgo constituye un elemento necesario para evitar una interpretación generalizada de las predicciones y para establecer criterios de evaluación que permitan determinar si el modelo mantiene un comportamiento adecuado cuando se aplica a diferentes escenarios epidemiológicos y territoriales.

8.5. Evaluación de fairness

En el presente proyecto, debido a que el modelo tiene como objetivo predecir casos de dengue a partir de información epidemiológica, climática e histórica, la evaluación de fairness no se orienta a atributos personales de los pacientes, sino principalmente a las diferencias que puedan presentarse entre territorios y periodos de tiempo. Por esta razón, se analizaron tres dimensiones de equidad relevantes para el problema: la equidad temporal, que evalúa si el modelo funciona de manera similar en años epidémicos y no epidémicos; la equidad estacional, que analiza su comportamiento entre la temporada de alta y baja transmisión; y la equidad de magnitud, que examina si el modelo es igual de preciso en semanas con pocos y muchos casos. Adicionalmente, se incorporó una reflexión sobre la equidad territorial.

8.6. Métricas de equidad

Para evaluar la equidad se utilizó principalmente el error relativo, que expresa el error del modelo como una proporción del número real de casos. Esta métrica resulta más apropiada que el error absoluto para comparar el desempeño entre grupos con distinta cantidad de casos, ya que un mismo error absoluto tiene un significado diferente según la magnitud de los casos reales. También se analizó el sesgo del modelo, entendido como la tendencia a sobreestimar o subestimar los casos, por su relevancia particular en el contexto de las alertas sanitarias.

8.7. Resultados del análisis de sesgos

- **Equidad temporal.** El modelo mantiene un comportamiento equitativo entre años epidémicos y de baja transmisión. El error relativo en el año epidémico 2022 fue del 20%, incluso menor que el del año de baja transmisión 2023 (26%). Aunque el error absoluto fue mayor en 2022 debido al mayor volumen de casos, proporcionalmente el modelo se mantiene confiable durante los años de brote, que son los más críticos.
- **Equidad estacional.** En la temporada de alta transmisión, el modelo tiende a sobreestimar ligeramente los casos (sesgo promedio de +12), mientras que en la temporada baja tiende a subestimar levemente (sesgo de -7.4). Su error relativo fue menor en la temporada alta (16%) que en la baja (22%). Este comportamiento es favorable para la salud pública, ya que el modelo actúa de manera preventiva justo en la época de mayor riesgo.
- **Equidad de magnitud.** El error relativo se mantiene parejo en los niveles medio y alto de casos (entre 13% y 16%), incluyendo las semanas de mayor transmisión. El nivel de casos bajos presentó un error relativo mayor (34%), lo cual es esperable, ya que un error pequeño en términos absolutos representa un porcentaje elevado cuando los casos son pocos; sin embargo, esto tiene poca relevancia sanitaria por tratarse de periodos de baja transmisión.
- **Tipo de error.** El modelo subestima en el 51% de las semanas y sobreestima en el 49%, lo que indica ausencia de un sesgo sistemático global. Combinado con el análisis

estacional, se observa que las subestimaciones se concentran en temporada baja (bajo riesgo) y las sobreestimaciones en temporada alta (mayor protección).

8.8. Medidas de mitigación

Aunque el análisis mostró un comportamiento equitativo del modelo en sus dimensiones temporal, estacional y de magnitud, se identificaron medidas orientadas a mantener y mejorar la equidad. En primer lugar, se recomienda la actualización periódica de los datos, de manera que el modelo incorpore los cambios en el comportamiento de la enfermedad y no quede sesgado hacia patrones históricos. En segundo lugar, para atender la limitación de equidad territorial, se recomienda el desarrollo de versiones departamentales del modelo, que permitan una atención proporcional al riesgo de cada zona. Finalmente, se recomienda el monitoreo continuo del desempeño del modelo por período y territorio, con el fin de detectar oportunamente posibles desigualdades en su comportamiento.

8.9. Limitaciones éticas del modelo

El modelo presenta limitaciones éticas que deben reconocerse para un uso responsable. La principal es que, al operar a nivel nacional, el modelo puede ocultar desigualdades entre departamentos: un desempeño favorable a nivel nacional podría coexistir con un comportamiento deficiente en territorios específicos, lo que podría dejar desatendidas a poblaciones de zonas con menor cantidad de casos o menor capacidad de vigilancia. Asimismo, el modelo no incorpora factores socioeconómicos ni condiciones locales que influyen en la vulnerabilidad de las poblaciones frente al dengue. Por estas razones, el modelo debe entenderse como una herramienta de apoyo que complementa, pero no reemplaza, el criterio de los profesionales de la salud, y sus resultados deben interpretarse siempre considerando el contexto territorial y social.

9. Prototipo funcional

9.1. Objetivo del prototipo

El prototipo tiene como objetivo poner a disposición de los usuarios el modelo de predicción desarrollado, mediante una aplicación interactiva que permita consultar estimaciones de casos de dengue de manera sencilla. La finalidad es demostrar que el modelo puede utilizarse como una herramienta práctica de apoyo a la vigilancia epidemiológica, y no únicamente como un ejercicio analítico. El prototipo busca acercar los resultados del modelo a usuarios que no necesariamente tienen conocimientos técnicos en aprendizaje automático.

9.2. Arquitectura del sistema

El sistema se compone de tres elementos principales. El primero es el modelo de predicción previamente entrenado, que se almacena en un archivo para su posterior uso. El segundo es la aplicación web, desarrollada con la biblioteca Streamlit, que constituye la interfaz con la que interactúa el usuario. El tercero es el conjunto de datos histórico, que se utiliza para mostrar el comportamiento del modelo frente a los casos reales. La aplicación carga el modelo entrenado y los datos, procesa las entradas del usuario y presenta las predicciones y visualizaciones correspondientes.

9.3. Tecnologías utilizadas

El prototipo fue desarrollado en el lenguaje de programación Python. Para la construcción de la interfaz web se utilizó Streamlit, una biblioteca que permite crear aplicaciones interactivas de manera sencilla. El modelo de predicción corresponde a XGBoost, seleccionado como modelo final del estudio. Para el manejo y procesamiento de los datos se emplearon las

bibliotecas Pandas y NumPy, mientras que para las visualizaciones se utilizó Matplotlib. El modelo entrenado se almacena y se carga mediante la biblioteca Joblib.

9.4. Flujo de funcionamiento

El funcionamiento de la aplicación sigue un flujo definido. Al iniciarse, la aplicación carga el modelo previamente entrenado y el conjunto de datos histórico. Posteriormente, presenta al usuario una interfaz con dos secciones principales: un predictor interactivo y un tablero histórico. En el predictor, el usuario ajusta las condiciones de entrada y la aplicación genera una predicción en tiempo real. En el tablero, la aplicación muestra la comparación entre las predicciones del modelo y los casos reales del período de prueba.

9.5. Entrada de datos

En la sección del predictor interactivo, el usuario ingresa la información mediante controles deslizantes. Las entradas se organizan en dos grupos. El primero corresponde al historial reciente de casos, e incluye los casos de la semana anterior, el promedio de casos de las últimas cuatro semanas y la semana epidemiológica que se desea predecir. El segundo grupo corresponde a las condiciones climáticas, e incluye la temperatura promedio, la precipitación semanal y la humedad promedio. Las variables que el modelo utiliza pero que no se controlan directamente mediante los deslizadores toman su valor mediano histórico, lo que permite generar una predicción completa a partir de las entradas principales.




9.6. Procesamiento

Una vez que el usuario ingresa los valores, la aplicación construye internamente el conjunto completo de variables que el modelo necesita, combinando las entradas del usuario con los valores por defecto de las demás variables. A partir de la semana epidemiológica indicada, la aplicación calcula automáticamente las variables derivadas correspondientes, como la codificación cíclica de la semana y el indicador de temporada lluviosa. El conjunto de variables resultantes se entrega al modelo para generar la predicción.

9.7. Predicción


El modelo genera la predicción del número de casos esperado para la siguiente semana. Debido a que el modelo fue entrenado utilizando una transformación logarítmica de la variable objetivo, la aplicación revierte esta transformación para presentar el resultado en la escala original, es decir, en número de casos. El valor obtenido se muestra de manera destacada al usuario.



9.8. Visualización de resultados


En la sección del tablero histórico, la aplicación permite al usuario seleccionar un año del período de prueba y visualizar una gráfica que compara los casos reales con los casos predichos por el modelo a lo largo de las semanas de ese año. Adicionalmente, se presentan las métricas correspondientes al año seleccionado, incluyendo el error absoluto medio, el total de casos reales y el total de casos predichos. Esta visualización permite al usuario apreciar el desempeño del modelo frente a datos reales.






9.9. Sistema de alertas de brote

La aplicación incorpora un indicador cualitativo del nivel de transmisión asociado a la predicción. Con base en el número de casos estimado, la aplicación clasifica la situación en tres niveles: bajo, moderado y alto. Cuando la predicción supera el umbral correspondiente al nivel alto, la aplicación muestra una alerta que sugiere considerar acciones preventivas. Este sistema de alertas busca traducir el resultado numérico del modelo en una señal comprensible para la toma de decisiones.



Nota: las variables no ajustadas manualmente usan su valor mediano histórico. Esta es una herramienta de apoyo; las decisiones deben validarse con criterio epidemiológico profesional.

Proyecto de grado — Universidad de El Salvador. Datos: OpenDengue (CC BY-SA) y NASA POWER. Modelo de apoyo a la vigilancia epidemiológica, no sustituye el criterio profesional.



9.10. Interfaz del prototipo

La interfaz de la aplicación fue diseñada de manera sencilla e intuitiva, organizando la información en dos pestañas para separar claramente las dos funcionalidades principales. La aplicación incluye un encabezado descriptivo, controles claramente etiquetados y notas explicativas que orientan al usuario sobre el funcionamiento y las limitaciones de la herramienta.

9.11. Pruebas funcionales

Se realizaron pruebas funcionales para verificar el correcto funcionamiento de la aplicación. Se comprobó que los controles de entrada respondieran adecuadamente, que las predicciones se generaran correctamente al modificar los valores, que la reversión de la transformación logarítmica produjera resultados en la escala esperada, y que el tablero histórico mostrara correctamente las gráficas y métricas para cada año seleccionado. La

aplicación fue ejecutada de manera local, verificando su correcto funcionamiento en el entorno de pruebas.

9.12. Limitaciones del prototipo

El prototipo presenta algunas limitaciones que deben considerarse. En primer lugar, el predictor interactivo utiliza valores medianos para las variables que no se controlan directamente mediante los deslizadores, por lo que las predicciones de esta sección tienen un carácter ilustrativo, orientado a mostrar cómo responde el modelo ante cambios en las variables principales. Las predicciones del tablero histórico, en cambio, utilizan los datos reales completos. En segundo lugar, el prototipo opera a nivel nacional, por lo que no permite realizar predicciones diferenciadas por departamento. En tercer lugar, la herramienta constituye un prototipo con fines demostrativos y académicos, por lo que una eventual implementación en un entorno real requeriría validaciones adicionales, integración con los sistemas de información existentes y un proceso de actualización periódica de los datos.

10. Impacto social y recomendaciones de política pública

10.1. Impacto social esperado

El dengue representa una carga significativa para el sistema de salud pública de El Salvador, con años epidémicos que generan decenas de miles de casos sospechosos y una presión considerable sobre los servicios sanitarios. El desarrollo de una herramienta predictiva basada en aprendizaje automático tiene el potencial de contribuir a una respuesta más anticipada y organizada frente a la enfermedad.

El impacto social esperado del modelo se orienta principalmente hacia el fortalecimiento de la capacidad de anticipación del sistema de vigilancia epidemiológica. Al disponer de estimaciones sobre el comportamiento de los casos, las autoridades sanitarias pueden pasar de un enfoque reactivo, en el que las acciones se toman una vez que el brote ya está en curso, hacia un enfoque preventivo, en el que los recursos se preparan antes de que la transmisión alcance sus niveles más altos. Esta anticipación puede traducirse en una reducción del impacto de los brotes sobre la población, especialmente sobre los grupos más vulnerables.

10.2. Aplicaciones potenciales en vigilancia epidemiológica

El modelo desarrollado puede integrarse como una herramienta complementaria dentro de los procesos de vigilancia epidemiológica que realiza el Ministerio de Salud. Su aplicación semanal permitiría contar con una estimación cuantitativa del comportamiento esperado de los casos, que se sumaría a los indicadores tradicionales utilizados en los boletines epidemiológicos.

Una aplicación particularmente relevante es el seguimiento del comportamiento estacional. El análisis realizado confirmó que los casos de dengue se concentran de manera consistente en la temporada lluviosa, aproximadamente entre las semanas epidemiológicas 18 y 43. El modelo permite monitorear esta transición y estimar la intensidad esperada de la temporada, apoyando la planificación de las acciones de vigilancia antes del inicio del período de mayor transmisión.

10.3. Utilidad para la toma de decisiones

La utilidad del modelo para la toma de decisiones se fundamenta en su capacidad para dimensionar el comportamiento de los casos con una precisión razonable. Durante la evaluación sobre el conjunto de prueba, el modelo estimó el total anual de casos del año

epidémico 2022 con un error cercano al 4%, lo que demuestra su capacidad para aproximar la magnitud de un período de alta transmisión. Esta información resulta valiosa para las autoridades responsables de asignar recursos, ya que permite estimar la demanda esperada sobre los servicios de salud.

No obstante, el modelo debe entenderse como una herramienta de apoyo a la decisión y no como un sustituto del criterio profesional. Las predicciones proporcionan un insumo adicional que, combinado con el conocimiento epidemiológico y el contexto local, contribuye a decisiones mejor informadas.

10.4. Identificación temprana de brotes

La identificación temprana de brotes constituye una de las aplicaciones de mayor valor de la herramienta. El modelo con información reciente de casos permite predecir con alta precisión el comportamiento de la semana siguiente, lo que facilita detectar incrementos sostenidos que puedan anticipar el inicio de un brote.

Sin embargo, el estudio también identificó una limitación importante que debe orientar el uso realista de la herramienta: los experimentos demostraron que un modelo basado únicamente en variables climáticas, sin información reciente de casos, no logra anticipar los brotes con precisión suficiente. Este hallazgo indica que la transmisión del dengue depende fuertemente de su propia dinámica reciente, la cual refleja factores no capturados por el clima, como la inmunidad poblacional, los serotipos circulantes y la densidad del vector. En consecuencia, la identificación temprana de brotes requiere necesariamente el mantenimiento de una vigilancia continua de casos; el modelo potencia esa vigilancia, pero no puede reemplazarla.

10.5. Optimización de recursos sanitarios

La capacidad predictiva del modelo puede contribuir a una asignación más eficiente de los recursos sanitarios. Al anticipar los períodos de mayor transmisión, las autoridades pueden planificar con antelación la distribución de insumos médicos, la disponibilidad de camas hospitalarias, el refuerzo de personal en las zonas de mayor riesgo y la organización de las campañas de control vectorial.

El análisis de equidad realizado mostró un comportamiento favorable del modelo en este sentido: en la temporada de alta transmisión, el modelo tiende a sobreestimar ligeramente los casos, lo que desde la perspectiva de la planificación sanitaria representa una postura preventiva conveniente, al alertar con margen suficiente en los períodos de mayor riesgo.

10.6. Recomendaciones de política pública

A partir de los resultados del estudio, se formulan las siguientes recomendaciones orientadas al fortalecimiento de la vigilancia y respuesta frente al dengue:

- **Vigilancia epidemiológica anticipada.** Incorporar las estimaciones del modelo como un insumo complementario en los procesos regulares de vigilancia, utilizándolas para anticipar el comportamiento esperado de los casos semana a semana.
- **Preparación de los servicios de salud.** Utilizar las predicciones de intensidad de la temporada para planificar con antelación la capacidad hospitalaria, los insumos y el personal, especialmente antes del inicio de la temporada lluviosa.
- **Campañas de prevención focalizadas.** Orientar las campañas de sensibilización y eliminación de criaderos hacia los períodos previos al aumento esperado de casos, maximizando su efecto preventivo.

- **Control vectorial oportuno.** Programar las acciones de control del mosquito de manera anticipada a los períodos de mayor riesgo estimados por el modelo, en lugar de ejecutarlas una vez iniciado el brote.
- **Gestión de recursos.** Emplear la estimación de la magnitud esperada de los casos para la asignación presupuestaria y logística de la respuesta sanitaria.
- **Sistemas de alerta temprana.** Integrar el modelo dentro de un sistema de alerta que combine las predicciones con los umbrales epidemiológicos oficiales, como el canal endémico, para generar señales de alerta oportunas.

10.7. Recomendaciones para implementación institucional

Para una eventual implementación institucional de la herramienta, se recomienda considerar los siguientes aspectos. En primer lugar, la herramienta debe integrarse a los flujos de trabajo existentes del Ministerio de Salud, de manera que complemente y no duplique los procesos de vigilancia actuales. En segundo lugar, es necesario establecer un mecanismo de actualización periódica de los datos, que permita al modelo incorporar la información epidemiológica y climática más reciente y mantener su vigencia. En tercer lugar, se recomienda acompañar la implementación con una capacitación del personal responsable, orientada a la correcta interpretación de las predicciones y de sus limitaciones. Finalmente, debe establecerse un monitoreo continuo del desempeño del modelo, que permita detectar posibles degradaciones en su capacidad predictiva ante cambios en el comportamiento de la enfermedad.

10.8. Escalabilidad del modelo

El modelo desarrollado en esta etapa opera a nivel nacional, lo que constituye tanto una fortaleza como una limitación. Su principal ventaja es la disponibilidad de una serie de datos continua y estandarizada que permite una predicción robusta del comportamiento agregado del país. Sin embargo, el análisis de equidad evidenció que un modelo nacional puede ocultar desigualdades entre departamentos, ya que un promedio nacional favorable podría coexistir con brotes localizados desatendidos en territorios específicos.

En consecuencia, la principal línea de escalabilidad recomendada es la extensión del modelo hacia un enfoque departamental, que permita generar predicciones diferenciadas por territorio y garantizar una atención proporcional al riesgo real de cada zona. Esta extensión dependería de la disponibilidad de datos epidemiológicos desagregados por departamento con resolución semanal y cobertura temporal suficiente. Adicionalmente, la metodología desarrollada es potencialmente aplicable a otras enfermedades transmitidas por vectores con comportamiento estacional similar, así como a otros países de la región centroamericana que compartan condiciones climáticas y epidemiológicas comparables.

11. Discusión

11.1. Interpretación de los resultados

Los resultados obtenidos muestran que la predicción semanal de casos de dengue en El Salvador presenta una fuerte dependencia de la dinámica reciente de la enfermedad. El modelo XGBoost optimizado alcanzó un MAE de 34.07 casos, un RMSE de 50.82 y un R^2 de 0.875 sobre el conjunto de prueba. Estos resultados indican que el modelo fue capaz de reproducir una proporción importante de la variabilidad observada en los casos durante períodos que no fueron utilizados para su entrenamiento o selección, sin embargo, en comparación con la línea base, el modelo de persistencia obtuvo un MAE de 29.82, un RMSE

de 50.86 y un R^2 de 0.875, por lo que presentó un error absoluto medio ligeramente inferior al XGBoost optimizado, mientras que ambos modelos alcanzaron el mismo coeficiente de determinación y valores prácticamente equivalentes de RMSE. Esto demuestra que la información correspondiente a la semana anterior contiene una capacidad predictiva considerable para anticipar el comportamiento de los casos durante la semana siguiente.

Las variables climáticas también aportaron información al modelo, aunque su influencia fue menor que la correspondiente al historial reciente de casos. La precipitación con un rezago de dos semanas presentó una influencia relevante entre las variables climáticas, lo que resulta compatible con la existencia de efectos temporales entre las condiciones ambientales y la dinámica de transmisión del dengue.

Otro resultado importante corresponde al ejercicio realizado sin utilizar rezagos de casos. En este escenario, el desempeño disminuyó considerablemente, alcanzando un MAE de 109.50 y un R^2 de -0.099 . Este resultado indica que las variables climáticas y estacionales utilizadas por sí solas no fueron suficientes para reproducir adecuadamente la dinámica de los casos durante el período de prueba.

Por tanto, los resultados no deben interpretarse como evidencia de que las variables climáticas carecen de relación con el dengue. Más bien, muestran que, dentro de las variables disponibles y bajo el horizonte de predicción utilizado, la información reciente de casos contiene una señal predictiva considerablemente mayor. El clima puede contribuir a establecer condiciones favorables para la transmisión, pero la predicción inmediata de los casos también depende de factores epidemiológicos que no se encuentran representados directamente en el conjunto de datos.

En este sentido, el modelo desarrollado a la actualidad, debe entenderse principalmente como una herramienta de **predicción de corto plazo** apoyada por la vigilancia epidemiológica existente, y no como un sistema capaz de anticipar por sí solo la aparición de brotes con varios meses de anticipación.

11.2. Comparación con estudios previos

Los resultados obtenidos son consistentes con la literatura que señala la importancia de incorporar variables climáticas y temporales en los modelos de predicción de dengue. Los estudios de predicción desarrollados en Latinoamérica han identificado de manera recurrente variables como temperatura, precipitación y humedad como factores potencialmente relevantes para explicar la variabilidad temporal de la enfermedad. [1]

La incorporación de estas variables en el presente estudio permitió evaluar su contribución conjuntamente con la información epidemiológica histórica. Esta diferencia es relevante, debido a que el comportamiento del dengue no depende exclusivamente de las condiciones ambientales, sino también de la dinámica epidemiológica previa.

El hallazgo relacionado con la precipitación rezagada también es compatible con la hipótesis de que las condiciones ambientales pueden producir efectos que no se manifiestan inmediatamente en el número de casos. La precipitación puede modificar la disponibilidad de criaderos y favorecer cambios posteriores en la población del vector, por lo que resulta razonable considerar rezagos temporales al analizar la relación entre clima y dengue.

Asimismo, la importancia observada de los rezagos epidemiológicos coincide con el comportamiento esperado de una serie temporal epidemiológica. La utilización de información correspondiente a semanas anteriores permite representar la persistencia de la transmisión y capturar tendencias recientes que no pueden ser explicadas únicamente mediante variables ambientales, no obstante, los resultados del presente estudio deben interpretarse considerando las características del conjunto de datos, el período analizado, la resolución

semanal y el contexto epidemiológico de El Salvador, ya que estas variables pueden diferir de los resultados en investigaciones realizadas en otros países de la región, por esta razón, los resultados no deben de extrapolarse directamente a otros países sin realizar estas validaciones. La principal contribución frente a los enfoques basados exclusivamente en variables climáticas consiste, en mostrar experimentalmente la diferencia de desempeño entre un modelo que incorpora información reciente de casos y otro que intenta realizar la predicción utilizando únicamente información climática y estacional.

11.3. Aportes del estudio

El presente estudio, aporta una metodología para la predicción semanal de casos de dengue en El Salvador, mediante la integración de variables epidemiológicas y climáticas.

Uno de sus principales aportes consiste en la construcción de un dataset de cobertura nacional y con casos semanales, permitiendo analizar en conjunto la evolución temporal de los casos y las condiciones ambientales.

Otro de sus aportes corresponde a la aplicación de la estrategia de evaluación temporal, la separación del dataset en las diferentes etapas, permitió validar las particiones temporales de los casos y sus condiciones ambientales, el estudio incorpora las técnicas de validación SHAP, el cual constituye otro aporte importante ya que permite no solo analizar el desempeño predictivo del modelo, si no también las variables que tuvieron mayor influencia sobre sus predicciones.

Finalmente, el desarrollo de un prototipo funcional permite trasladar los resultados del análisis experimental hacia una herramienta interactiva. De esta manera, el proyecto integra las etapas de preparación de datos, modelado, evaluación, interpretación y visualización dentro de una misma propuesta.

11.4. Fortalezas

Entre las principales fortalezas del estudio, se encuentra el uso de una estrategia de validación temporal, adecuada para una problemática donde la variable objetivo presenta dependencia cronológica. Esta metodología reduce el riesgo de utilizar información futura durante el entrenamiento y permite evaluar el modelo sobre períodos posteriores.

El estudio también presenta como fortaleza la comparación de diferentes enfoques de modelado. La evaluación de Regresión Lineal, Random Forest, XGBoost y técnicas de ensemble permitió analizar diferentes capacidades para representar relaciones lineales y no lineales.

Finalmente, la incorporación de análisis de interpretabilidad, sesgos, fairness y consideraciones éticas amplía la evaluación más allá de las métricas predictivas tradicionales. Esto resulta particularmente relevante debido a que el modelo se plantea como una posible herramienta de apoyo en un contexto de salud pública.

11.5. Limitaciones

Una de las principales limitaciones del estudio corresponde al tamaño del conjunto de datos. Aunque se dispone de aproximadamente once años de observaciones semanales, el total de registros continúa siendo relativamente reducido para evaluar arquitecturas de aprendizaje profundo complejas. Esta limitación fue una de las razones para no utilizar LSTM como modelo principal.

Otra limitación corresponde a la disponibilidad de variables explicativas. El modelo utiliza información climática y epidemiológica histórica, pero no incorpora directamente variables como densidad del vector, serotipos circulantes, inmunidad poblacional, movilidad, acciones

de control vectorial, características socioeconómicas o condiciones específicas de las viviendas.

También existe una limitación relacionada con la resolución espacial. El modelo desarrollado opera a nivel nacional, por lo que las predicciones representan el comportamiento agregado de El Salvador y pueden ocultar diferencias importantes entre departamentos.

Asimismo, la fuerte dependencia de los rezagos de casos limita la capacidad del modelo para realizar predicciones de largo plazo. El experimento sin estas variables mostró una disminución importante del desempeño, lo que indica que la herramienta depende de la disponibilidad continua de información epidemiológica reciente.

Finalmente, el prototipo desarrollado tiene carácter académico y demostrativo. Antes de utilizarlo en un entorno institucional sería necesario realizar validaciones adicionales con datos nuevos, establecer mecanismos de actualización y evaluar su comportamiento de manera continua.

11.6. Implicaciones para la vigilancia del dengue en El Salvador

Los resultados sugieren que los modelos predictivos pueden utilizarse como herramientas complementarias dentro de la vigilancia epidemiológica del dengue en El Salvador. En particular, el modelo puede proporcionar una estimación adicional del comportamiento esperado durante las semanas siguientes y contribuir a identificar cambios en la tendencia de los casos, sin embargo, la fuerte dependencia de la información epidemiológica reciente tiene una implicación importante, el modelo no elimina la necesidad de mantener sistemas de vigilancia activos. Por el contrario, requiere que la información de casos continúe siendo recopilada y actualizada para mantener su capacidad predictiva.

El modelo puede ser utilizado como un componente adicional de un sistema de alerta temprana, complementando indicadores epidemiológicos tradicionales y otros mecanismos de vigilancia. Las predicciones podrían contribuir a priorizar el análisis de determinadas semanas o períodos, especialmente cuando se observe un incremento sostenido de los casos, su implementación también debería considerar la posibilidad de generar predicciones diferenciadas por territorio, un modelo nacional puede ser útil para observar la tendencia general del país, pero no necesariamente refleja adecuadamente la situación por cada departamento o municipio.

En consecuencia, el principal valor potencial del modelo se encuentra en su utilización como instrumento complementario para anticipar y dimensionar cambios en la transmisión, siempre acompañado de la interpretación de profesionales responsables de la vigilancia epidemiológica.

12. Conclusiones

12.1. Cumplimiento de los objetivos

El estudio ha permitido desarrollar y evaluar modelos de Machine Learning orientados a la predicción semanal de casos de dengue en El Salvador mediante la integración de información epidemiológica histórica disponible y variables climáticas.

Se recopiló y estructuró información correspondiente al período 2014–2024, integrando casos de dengue y variables climáticas con resolución semanal. A partir de estos datos se desarrollaron variables derivadas, componentes estacionales y rezagos temporales que permitieron representar diferentes características de la dinámica de la enfermedad.

Se evaluaron modelos de Regresión Lineal, Random Forest y XGBoost, además de técnicas de ensemble basadas en los modelos de árboles. Posteriormente, Random Forest y XGBoost

fueron optimizados mediante búsqueda de hiperparámetros utilizando validación cruzada temporal.

La evaluación final permitió seleccionar XGBoost optimizado como el modelo de Machine Learning con mejor comportamiento dentro de los modelos evaluados, alcanzando un MAE de 34.07 casos, un RMSE de 50.82 y un R^2 de 0.875 sobre el conjunto de prueba.

También se desarrolló un prototipo funcional mediante Streamlit, permitiendo consultar predicciones y visualizar el comportamiento histórico de los casos reales y predichos.

12.2. Principales hallazgos

Uno de los principales hallazgos fue la elevada importancia de la información epidemiológica reciente. Las variables de rezago de casos fueron las características con mayor influencia en las predicciones, destacando especialmente el promedio de casos de las últimas cuatro semanas.

El segundo hallazgo corresponde a la contribución de las variables climáticas. Aunque su influencia fue menor que la de los rezagos epidemiológicos, la precipitación rezagada presentó una importancia relevante, lo que respalda la necesidad de considerar efectos temporales al analizar la relación entre condiciones ambientales y dengue.

El tercer hallazgo corresponde a la importancia de la línea base. La persistencia temporal obtuvo un desempeño muy cercano al del modelo XGBoost optimizado, demostrando que el comportamiento reciente de los casos constituye una fuente de información altamente predictiva para el horizonte de una semana.

Asimismo, el experimento sin rezagos epidemiológicos mostró una reducción considerable del desempeño. Esto evidencia que las variables climáticas disponibles por sí solas no fueron suficientes para anticipar adecuadamente la dinámica de los casos durante el período evaluado.

Finalmente, el análisis demostró que el modelo fue capaz de aproximar la magnitud anual de períodos de alta transmisión. Para 2022, el modelo estimó aproximadamente 17,200 casos frente a 16,542 observados, equivalente a una diferencia cercana al 4%.

12.3. Modelo seleccionado

El modelo seleccionado para el prototipo fue XGBoost optimizado, utilizando los hiperparámetros obtenidos mediante validación cruzada temporal: `learning_rate=0.03`, `max_depth=3`, `n_estimators=200` y `subsample=0.8`.

La selección se fundamentó en su desempeño entre los modelos de Machine Learning evaluados, particularmente en su MAE de 34.07 y R^2 de 0.875 sobre el conjunto de prueba.

No obstante, el desempeño de la línea base demuestra que el modelo seleccionado debe utilizarse como complemento de estrategias sencillas de predicción y de los mecanismos existentes de vigilancia epidemiológica. Su principal valor adicional consiste en integrar múltiples variables y proporcionar una estructura que puede ser interpretada mediante técnicas como SHAP.

12.4. Aportes del prototipo

El prototipo desarrollado permitió demostrar la posibilidad de utilizar el modelo de Machine Learning fuera del entorno experimental de los notebooks.

El prototipo permite introducir condiciones relacionadas con el historial reciente de casos y determinadas variables climáticas para obtener una estimación del número esperado de casos. Además, incorpora un tablero histórico que permite comparar las predicciones con los casos reales del período de prueba.

La incorporación de niveles de transmisión en el prototipo permite complementar el resultado cuantitativo del modelo con una categorización visual que facilita su interpretación por parte de los usuarios. A partir del número estimado de casos para la semana siguiente, el sistema asigna una categoría de nivel de transmisión, permitiendo identificar de manera rápida situaciones que podrían requerir mayor atención. Estas categorías tienen un carácter demostrativo dentro del prototipo y no sustituyen los umbrales epidemiológicos oficiales ni los criterios establecidos por las autoridades sanitarias.

De esta manera, el prototipo constituye una prueba de concepto para demostrar cómo los resultados del modelo podrían integrarse posteriormente en una herramienta de apoyo a la vigilancia epidemiológica.

12.5. Aportes para la toma de decisiones

El principal aporte potencial del modelo para la toma de decisiones consiste en proporcionar una estimación adicional sobre el comportamiento esperado de los casos durante las semanas siguientes.

Esta información puede contribuir a complementar los procesos de vigilancia, planificación de recursos, preparación de los servicios de salud y programación de acciones preventivas.

No obstante, los resultados obtenidos también establecen una condición fundamental para su utilización: las predicciones deben interpretarse conjuntamente con la información epidemiológica actual, los indicadores oficiales y el conocimiento de los responsables de la vigilancia. Por tanto, el modelo no debe utilizarse como un mecanismo automático para tomar decisiones sanitarias, sino como una herramienta analítica que proporciona información adicional para apoyar procesos de planificación y respuesta.

13. Recomendaciones

13.1. Recomendaciones técnicas

Se recomienda mantener una actualización periódica del conjunto de datos utilizado por el modelo, incorporando nuevos registros epidemiológicos y climáticos conforme estén disponibles.

También se recomienda establecer un proceso de monitoreo continuo del desempeño del modelo mediante métricas como MAE, RMSE y R^2 , comparándolo periódicamente con la línea base de persistencia. Esto permitiría detectar posibles cambios en su capacidad predictiva a medida que evolucione el comportamiento epidemiológico.

Se recomienda evaluar diferentes horizontes de predicción. El modelo actual está orientado principalmente a la predicción de corto plazo, por lo que sería conveniente estudiar su comportamiento a dos, tres, cuatro o más semanas y determinar hasta qué punto conserva capacidad predictiva, también sería conveniente incorporar intervalos de predicción, mayor segregación territorial, además del valor puntual estimado. Esto permitiría representar explícitamente la incertidumbre asociada a cada predicción y proporcionaría información más útil para la planificación.

Finalmente, se recomienda implementar un proceso automatizado de reentrenamiento y validación antes de incorporar nuevos datos al modelo productivo, evitando que la actualización automática introduzca errores o información inconsistente.

13.2. Recomendaciones institucionales

Se recomienda una eventual implementación institucional, que integre el modelo dentro de los procesos existentes de vigilancia epidemiológica, y actividades realizadas por el ministerio de salud para la prevención del dengue, tales como jornadas de abatización, fumigación,

inspección y eliminación de criaderos, entre otros, evitando que funcione como un sistema aislado.

La información generada por el modelo debería presentarse conjuntamente con indicadores epidemiológicos oficiales, canales endémicos y otros mecanismos de alerta utilizados por las autoridades sanitarias. Esto permitiría contextualizar las predicciones y reducir el riesgo de interpretar una estimación como una confirmación de un brote.

También se recomienda establecer responsabilidades claras para la interpretación y seguimiento de las predicciones. El resultado del modelo debe ser revisado por personal con conocimiento epidemiológico antes de utilizarse como fundamento para acciones de respuesta.

Otra recomendación corresponde a la ampliación territorial del sistema. Una segunda etapa de desarrollo podría incorporar información departamental o municipal, para identificar diferencias espaciales en la dinámica del dengue y evitar que las tendencias nacionales oculten incrementos localizados.

Finalmente, la implementación institucional debería acompañarse de capacitación para los usuarios, de manera que puedan interpretar correctamente las predicciones, comprender sus limitaciones y diferenciar entre una estimación del modelo y una alerta epidemiológica oficial.

13.3. Recomendaciones para futuras investigaciones

Como línea principal de investigación futura se recomienda desarrollar modelos con mayor resolución territorial, particularmente a nivel municipal. Esto permitiría estudiar si las variables que explican la dinámica nacional presentan comportamientos diferentes entre territorios.

También se recomienda ampliar el conjunto de variables incorporando información epidemiológica, estrategias y ambiental adicional. Entre las posibles variables se encuentran indicadores de control vectorial, densidad poblacional, movilidad, características socioeconómicas, disponibilidad de servicios de salud, índices entomológicos y circulación de serotipos.

Otra línea de investigación consiste en estudiar con mayor profundidad los efectos de rezago entre las variables climáticas y los casos de dengue. La identificación de los períodos de rezago más relevantes podría contribuir a desarrollar modelos orientados a horizontes de predicción superiores a una semana.

También sería relevante realizar una evaluación prospectiva del modelo. En lugar de evaluar únicamente períodos históricos, un estudio futuro podría implementar el modelo durante un período de vigilancia real y comparar sus predicciones con los casos posteriormente registrados.

Finalmente, se recomienda evaluar el sistema mediante estudios con participación de usuarios especialistas. Esto permitiría determinar no solamente si el modelo presenta un desempeño estadístico adecuado, sino también si la información proporcionada resulta comprensible, útil y compatible con los procesos reales de vigilancia epidemiológica.

Referencias bibliográficas

1. Cabrera, M., Leake, J., Naranjo-Torres, J., Valero, N., Cabrera, J. C., & Rodríguez-Morales, A. J. Dengue Prediction in Latin America Using Machine Learning and the One Health Perspective: A Literature Review. *Tropical Medicine and Infectious Disease*, 7(10), 322.
2. Clarke, J., Lim, A., Gupte, P., Pigott, D. M., van Panhuis, W. G., & Brady, O. J. OpenDengue: data from the OpenDengue database. Version 1.3. Figshare, 2025.

Anexos

Anexo 1. Etapas del proyecto

Preparación de los datos: revisión, integración, limpieza y transformación de los datos climáticos, epidemiológicos e históricos de casos de dengue.

División temporal: separación de los datos en conjuntos de entrenamiento, validación y prueba final, correspondientes a los períodos 2015–2021, 2022 y 2023, respectivamente.

Preprocesamiento: aplicación de las transformaciones necesarias para preparar las variables para el entrenamiento de los modelos, incluyendo el tratamiento de valores faltantes y la transformación de las variables cuando fue necesario.

Entrenamiento de modelos: aplicación de diferentes algoritmos de Machine Learning sobre el conjunto de entrenamiento, con el objetivo de identificar cuál presenta un mejor desempeño para la predicción de casos de dengue.

Validación y selección: evaluación de los modelos utilizando el conjunto correspondiente al año 2022, permitiendo comparar su desempeño y realizar el ajuste de los hiperparámetros.

Evaluación final: una vez seleccionado el modelo con mejor desempeño, este fue evaluado utilizando exclusivamente los datos correspondientes al año 2023, previamente reservados para este propósito.

Interpretación de resultados: análisis del desempeño del modelo seleccionado y estudio de la importancia de las variables utilizadas, con el propósito de identificar los factores que presentan mayor contribución a la predicción de los casos de dengue.

Anexo 2. Proyecto en github

Enlace a Github del proyecto:

<https://github.com/Melvillalta1/DengueSV/tree/main/entrega%202>